

第 4 章对偶理论

SMaLL

¹ 中国石油大学（华东）

SMaLL 课题组

small.sem.upc.edu.cn

liangxijunsd@163.com

2023

对偶理论

1. 对偶理论

1.1 Lagrange 对偶问题

1.2 弱对偶和强对偶

1.3 最优性条件

拉格朗日函数

标准形式的优化问题 (不一定是凸问题)

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && h_i(x) = 0, \quad i = 1, \dots, p \end{aligned} \tag{1}$$

变量 $x \in \mathbf{R}^n$, 定义域 \mathcal{D} , 最优值 p^*

拉格朗日函数: $L : \mathbf{R}^n \times \mathbf{R}^m \times \mathbf{R}^p \rightarrow \mathbf{R}$, 其中 $\text{dom} L = \mathcal{D} \times \mathbf{R}^m \times \mathbf{R}^p$,

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \tag{2}$$

- 目标函数和约束函数的加权和
- λ_i 是对应于不等式约束 $f_i(x) \leq 0$ 的 Lagrange 乘子
- ν_i 是对应于等式约束 $h_i(x) = 0$ 的 Lagrange 乘子

Lagrange 对偶函数

Lagrange 对偶函数: $g: \mathbf{R}^m \times \mathbf{R}^p \rightarrow \mathbf{R}$,

$$g(\lambda, \mathbf{v}) = \inf_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \lambda, \mathbf{v}) = \inf_{\mathbf{x} \in \mathcal{D}} \left(f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x}) \right) \quad (3)$$

g 是凹函数, 对一些 λ, ν 其取值可以为 $-\infty$

分析. g 是 (λ, ν) 的仿射函数族的逐点下确界 \Rightarrow 它是凹的, 即使原始问题不是凸的.

下界属性: 如果 $\lambda \succeq 0$, 那么 $g(\lambda, \nu) \leq p^*$

Lagrange 对偶函数

证明: 如果 \tilde{x} 是一个可行点, 即满足 $f_i(\tilde{x}) \leq 0$ $h_i(\tilde{x}) = 0$, 并且 $\lambda \succeq 0$, 可得

$$\sum_i^m \lambda_i f_i(x) + \sum_i^p v_i h_i(x) \leq 0 \quad (4)$$

因为第一项求和中的每一项都是非正的, 并且第二项求和中的每一项都为零,

$$L(\tilde{x}, \lambda, \mathbf{v}) = f_0(\tilde{\mathbf{x}}) + \sum_i^m \lambda_i f_i(\tilde{\mathbf{x}}) + \sum_i^p \nu_i h_i(\tilde{\mathbf{x}}) \leq f_0(\tilde{\mathbf{x}}) \quad (5)$$

因此

$$g(\boldsymbol{\lambda}, \mathbf{v}) = \inf_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) \leq L(\tilde{\mathbf{x}}, \boldsymbol{\lambda}, \mathbf{v}) \leq f_0(\tilde{\mathbf{x}}) \quad (6)$$

因为 $g(\lambda, v) \leq f_0(\tilde{x})$ 对所有的可行点 \tilde{x} 都成立, 故不等式 $g(\lambda, \nu) \leq p^*$ 成立。




图: 1 一个对偶可行点的下界

图 1 用 $x \in \mathbf{R}$ 并且有一个不等式约束的简单问题解释了不等式 $g(\lambda, \nu) \leq p^*$ 中的下界，实线为目标函数 f_0 ，虚数为约束函数 f_1 。可行集合为区间 $[-1, 1]$ 。最优点和最优值为 $x^* = -1, p^* = 1.08$ 。由于在可行集合上对 $\lambda \leq 0$ 有 $L(x, \lambda) \leq f_0(x)$ ，因此每一个函数 $L(x, \lambda)$ 的最小值都比 p^* 小。

线性方程的最小范数解

$$\begin{array}{ll}\text{minimize} & x^T x \\ \text{subject to} & Ax = b\end{array}\quad (7)$$

对偶函数

- lagrange 函数为 $L(x, \nu) = x^T x + \nu^T (Ax - b)$
- 为了最小化 L , 将梯度设置为零:

$$\nabla_x L(x, \nu) = 2x + A^T \nu = 0 \implies x = -(1/2)A^T \nu \quad (8)$$

- 插入 L 得到 g :

$$g(\nu) = L((-1/2)A^T \nu, \nu) = -\frac{1}{4}\nu^T A A^T \nu - b^T \nu \quad (9)$$

它是一个关于 ν 的凹二次函数

下界性质: $p^* \geq -(1/4)\nu^T A A^T \nu - b^T \nu$ 对于所有 ν

标准形式的 LP

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & Ax = b, \quad x \succeq 0\end{array}\quad (10)$$

对偶函数

- lagrange 函数为

$$\begin{aligned}L(x, \lambda, \nu) &= c^T x + \nu^T (Ax - b) - \lambda^T x \\ &= -b^T \nu + (c + A^T \nu - \lambda)^T x\end{aligned}\quad (11)$$

- L 是在 x 上的仿射函数, 因此

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) = \begin{cases} -b^T \nu & A^T \nu - \lambda + c = 0 \\ -\infty & \text{otherwise} \end{cases}\quad (12)$$

g 是一条直线, 定义域为 $\{(\lambda, \nu) \mid A^T \nu - \lambda + c = 0\}$, 因此是凹的

下界性质: $p^* \geq -b^T \nu$ if $A^T \nu + c \succeq 0$

等式约束范数最小化 (Ex.)

$$\begin{array}{ll}\text{minimize} & \|x\| \\ \text{subject to} & Ax = b\end{array}\quad (13)$$

对偶函数

$$g(\nu) = \inf_x (\|x\| - \nu^T Ax + b^T \nu) = \begin{cases} b^T \nu & \|A^T \nu\|_* \leq 1 \\ -\infty & \text{其他} \end{cases} \quad (14)$$

其中 $\|v\|_* = \sup_{\|u\| \leq 1} u^T v$, $\|\cdot\|$ 是对偶范数

证明:

- $\inf_x (\|x\| - y^T x) = \begin{cases} 0 & \|y\|_* \leq 1 \\ -\infty, & \text{否则} \end{cases}$
- 如果 $\|y\|_* \leq 1$, 那么 $\|x\| - y^T x \geq 0$ 对于任意 x , 如果 $x = 0$, 则相等
- 如果 $\|y\|_* > 1$, 令 $x = tu$ 其中 $\|u\| \leq 1, u^T y = \|y\|_* > 1$

$$\|x\| - y^T x = t(\|u\| - \|y\|_*) \rightarrow -\infty \quad \text{当 } t \rightarrow \infty \quad (15)$$

下界性质: $p^* \geq b^T \nu$ 如果 $\|A^T \nu\|_* \leq 1$

双向分区 (Two-way partitioning)

$$\begin{aligned} & \text{minimize} && x^T W x \\ & \text{subject to} && x_i^2 = 1, \quad i = 1, \dots, n \end{aligned} \tag{16}$$

- 非凸问题；可行集包含 2^n 个离散点
- 解释：将 $\{1, \dots, n\}$ 分成两个集合； W_{ij} 是将 i, j 分到相同集合的成本； $-W_{ij}$ 是分配到不同集合的成本

对偶函数

$$\begin{aligned} g(\nu) &= \inf_x \left(x^T W x + \sum_i \nu_i (x_i^2 - 1) \right) = \inf_x x^T (W + \mathbf{diag}(\nu)) x - \mathbf{1}^T \nu \\ &= \begin{cases} -\mathbf{1}^T \nu & W + \mathbf{diag}(\nu) \succeq 0 \\ -\infty & \text{其他} \end{cases} \end{aligned} \tag{17}$$

下界性质： $p^* \geq -\mathbf{1}^T \nu$ 如果 $W + \mathbf{diag}(\nu) \succeq 0$

例如： $\nu = -\lambda_{\min}(W)\mathbf{1}$ gives bound $p^* \geq n\lambda_{\min}(W)$

Lagrange 对偶和共轭函数

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && Ax \preceq b, \quad Cx = d \end{aligned} \tag{18}$$

对偶函数

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in \text{dom} f_0} (f_0(x) + (A^T \lambda + C^T \nu)^T x - b^T \lambda - d^T \nu) \\ &= -f_0^*(-A^T \lambda - C^T \nu) - b^T \lambda - d^T \nu \end{aligned} \tag{19}$$

- 共轭的定义: $f^*(y) = \sup_{x \in \text{dom} f} (y^T x - f(x))$
- 如果已知 f_0 的共轭, 则简化对偶的推导

例 (熵最大化)

$$f_0(x) = \sum_{i=1}^n x_i \log x_i, \quad f_0^*(y) = \sum_{i=1}^n e^{y_i - 1} \tag{20}$$

对偶问题

Lagrange 对偶问题

$$\max_{\lambda \succeq 0} g(\lambda, \nu) = \max_{\lambda \succeq 0} \min_x L(x, \lambda, \nu) \quad (21)$$

- Lagrange 对偶函数: 找到 p^* 上的最优下界
- 对偶问题为凸优化问题; 最优值记为 d^*
- 如果 $\lambda \succeq 0$, 则 $(\lambda, \nu) \in \text{dom} g$, 称 λ, ν 是对偶可行的

对偶问题

例 (标准形式 LP 及其对偶)

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & Ax = b \\ & x \succeq 0\end{array} \quad (22)$$

$$\begin{array}{ll}\text{minimize} & -b^T \nu \\ \text{subject to} & A^T \nu + c \succeq 0\end{array} \quad (23)$$

- 假设 $A \in \mathbb{R}^{m \times n}$, $m \ll n$
- 原始问题: $x \in \mathbb{R}^n$, 对偶问题 $\nu \in \mathbb{R}^m$;
- $m \ll n \rightarrow$ 对偶规划显著减少了变量个数
- 何时考虑对偶规划 (来减少变量) ?

较少的等式约束: 许多变量 \rightarrow 对偶问题

对偶理论

1. 对偶理论

1.1 Lagrange 对偶问题

1.2 弱对偶和强对偶

1.3 最优性条件

弱对偶和强对偶

弱对偶: $d^* \leq p^*$

- 总是成立（对于凸和非凸问题）
- 可以用来寻找难以解决的问题的最优值下界
例如, 解决 SDP（半正定规划）问题

$$\begin{aligned} & \text{maximize} && -\mathbf{1}^T \nu \\ & \text{subject to} && W + \mathbf{diag}(\nu) \succeq 0 \end{aligned} \tag{24}$$

给出了一个关于双向分配问题的下界

强对偶: $d^* = p^*$

- 一般不成立
- （通常）对于凸问题成立
- 在凸问题中保证强对偶的条件称为 **约束规范**

Slater 约束条件

Proposition

- 以下凸问题

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && Ax = b \end{aligned} \quad (25)$$

•

$$\exists x \in \text{int } \mathcal{D} : \quad f_i(x) < 0, \quad i = 1, \dots, m, \quad Ax = b \quad (26)$$

$$\mathcal{D} = \cap_{i=0}^m \text{dom } f_i(x)$$

\implies 强对偶性成立.

注意

- 也保证了达到对偶问题的最优解 (如果 $d^* > -\infty$)
- 仿射不等式不必与严格不等式同时成立: 如果 f_1, \dots, f_k 是仿射的, 则在下面条件成立时, 强对偶性成立:

$$\exists x \in \text{relint } \mathcal{D} : f_i(x) \leq 0, \quad i = 1, \dots, m, \quad f_i(x) < 0, \quad i = k+1, \dots, m, \quad Ax = b$$

不等式形式的 LP 问题

原问题

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & Ax \preceq b\end{array}\quad (27)$$

对偶函数

$$g(\lambda) = \inf_x ((c + A^T \lambda)^T x - b^T \lambda) = \begin{cases} -b^T \lambda & A^T \lambda + c = 0 \\ -\infty & \text{其他} \end{cases} \quad (28)$$

对偶问题

$$\begin{array}{ll}\text{maximize} & -b^T \lambda \\ \text{subject to} & A^T \lambda + c = 0, \quad \lambda \succeq 0\end{array}\quad (29)$$

- 由 Slater 条件得: 如果对某些 \tilde{x} , $A\tilde{x} \prec b$, 则 $p^* = d^*$
- 事实上, $p^* = d^*$ 除非原问题和对偶问题不可行

二次规划问题 (Ex.)

原问题 (假设 $P \in \mathbf{S}_{++}^n$)

$$\begin{array}{ll}\text{minimize} & x^T P x \\ \text{subject to} & A x \preceq b\end{array}\quad (30)$$

对偶函数

$$g(\lambda) = \inf_x (x^T P x + \lambda^T (A x - b)) = -\frac{1}{4} \lambda^T A P^{-1} A^T \lambda - b^T \lambda \quad (31)$$

对偶问题

$$\begin{array}{ll}\text{maximize} & -(1/4) \lambda^T A P^{-1} A^T \lambda - b^T \lambda \\ \text{subject to} & \lambda \succeq 0\end{array}\quad (32)$$

- 由 Slater 条件: 如果对某些 \tilde{x} , $A\tilde{x} \prec b$, 则 $p^* = d^*$
- 事实上, $p^* = d^*$ 总是成立

对偶理论

1. 对偶理论

1.1 Lagrange 对偶问题

1.2 弱对偶和强对偶

1.3 最优性条件

互补松弛度

假设强对偶成立, x^* 是原问题的最优解, (λ^*, ν^*) 是对偶问题的最优解

$$\begin{aligned} f_0(x^*) = g(\lambda^*, \nu^*) &= \inf_x \left(f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p \nu_i^* h_i(x) \right) \\ &\leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p \nu_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned} \quad (33)$$

因此, 这两个不等式取等号

- x^* 最小化 $L(x, \lambda^*, \nu^*)$
- $\lambda_i^* f_i(x^*) = 0$, $i = 1, \dots, m$ (称为互补松弛):

$$\lambda_i^* > 0 \implies f_i(x^*) = 0, \quad f_i(x^*) < 0 \implies \lambda_i^* = 0 \quad (34)$$

- x^* 是 $L(x, \lambda^*, \nu^*)$ 的最小值点 $\implies \nabla_x L(x, \lambda^*, \nu^*)|_{x=x^*} = 0$

Karush-Kuhn-Tucker (KKT) 条件 **

以下四个条件称为 **KKT 条件** (对于可微的 f_i, h_i):

1. 原始约束: $f_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, p$
2. 对偶约束: $\lambda \succeq 0$
3. 互补松弛条件: $\lambda_i f_i(x) = 0, i = 1, \dots, m$
4. Lagrange 函数在点 x 处的梯度为 0 :

$$\nabla f_0(x) + \sum_{i=1}^m \lambda_i \nabla f_i(x) + \sum_{i=1}^p \nu_i \nabla h_i(x) = 0 \quad (35)$$

Proposition

如果强对偶成立, 且 x, λ, ν 是原问题和对偶问题的最优解 \implies KKT 条件成立.

凸问题的 KKT 条件

定理

- 如果原问题是凸问题: f_i 是凸函数, h_i 是仿射函数
- 如果 $\tilde{x}, \tilde{\lambda}, \tilde{\nu}$ 满足 KKT 条件

$\Rightarrow \tilde{x}, (\tilde{\lambda}, \tilde{\nu})$ 是零对偶间隙的原始最优解和对偶最优解.

- 注意: 对于任意可微目标和约束函数的凸优化问题, 满足 KKT 条件的任何点是原始和对偶最优, 并且具有零对偶间隙。

证明:

- \tilde{x} : 原始可行解, $(\tilde{\lambda}, \tilde{\nu})$ 对偶可行解;
- $\tilde{\lambda}_i \geq 0 \Rightarrow L(x, \tilde{\lambda}, \tilde{\nu})$ 在 x 处是凸的;
- 梯度条件: $\nabla_x L(x, \tilde{\lambda}, \tilde{\nu})|_{x=\tilde{x}} = 0 \Rightarrow \tilde{x} = \operatorname{argmin}_x L(x, \tilde{\lambda}, \tilde{\nu})$
-

$$\begin{aligned} g(\tilde{\lambda}, \tilde{\nu}) &= L(\tilde{x}, \tilde{\lambda}, \tilde{\nu}) \\ &= f_0(\tilde{x}) + \sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{x}) + \sum_{i=1}^p \tilde{\nu}_i h_i(\tilde{x}) \\ &= f_0(\tilde{x}) \end{aligned}$$

应用: 支持向量机

- 二分类问题
- 训练集: $\{x_i, y_i\}_{i=1}^n$, $x_i \in \mathbb{R}^d$, $y_i \in \{1, -1\}$
- 线性分类器: $y = \langle w, x \rangle + b$
- 支持向量机分类

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_i(\langle w, x_i \rangle + b) \geq 1, i = 1 \cdots, n \end{aligned}$$

所有样本均正确分类.

- 验证其 Lagrange 对偶问题:

$$\begin{aligned} \max_{\alpha} \quad & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle + \langle \mathbf{1}, \alpha \rangle \\ \text{s.t.} \quad & \langle \alpha, y \rangle = 0 \\ & \alpha_i \geq 0, \quad i = 1, \dots, n \end{aligned}$$

应用: 支持向量机 (Ex.)

- 软间隔 (Soft-margin) 支持向量机分类

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i, i = 1 \cdots, n \end{aligned}$$

允许一些分类错误的样本.

- 验证其 Lagrange 对偶问题:

$$\begin{aligned} \max_{\alpha} \quad & -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle + \langle \mathbf{1}, \alpha \rangle \\ \text{s.t.} \quad & \langle \alpha, y \rangle = 0 \\ & C \geq \alpha_i \geq 0, \quad i = 1, \dots, n \end{aligned}$$

作业 I

1. 考虑如下优化问题

$$\begin{aligned} & \text{minimize} && x^2 - 2x + 1 \\ & \text{subject to} && (x - 1)(x - 5) \leq 0 \end{aligned} \tag{36}$$

其中 $\mathbf{x} \in \mathbf{R}^n$

- (1) 分析原问题，给出可行集、最优值以及最优解
- (2) 画出目标函数关于 x 的图像，并在图像上画出可行集、最优值以及最优解。画出 $\lambda=0.2$ 时，Lagrange 函数 $L(x, \lambda)$ 关于 x 的图像，验证下界性质： $p^* \geq \inf_x L(x, \lambda)$ 对 $\lambda \geq 0$ 成立。推导并画出 Lagrange 对偶函数 g 。

作业 II

2. 考虑如下凸分段线性函数最小化问题

$$\text{minimize} \quad \max_{i=1, \dots, m} (a_i^T \mathbf{x} + b_i) \quad (37)$$

其中 $\mathbf{x} \in \mathbf{R}^n$

(1) 考虑等式问题

$$\begin{aligned} &\text{minimize} \quad \max_{i=1, \dots, m} y_i \\ &\text{subject to} \quad \mathbf{a}_i^T \mathbf{x} + b_i = y_i, i = 1, \dots, m \end{aligned} \quad (38)$$

其中 $\mathbf{x} \in \mathbf{R}^n$, $\mathbf{y} \in \mathbf{R}^m$, 推导出 Lagrange 对偶问题。

(2) 将分段线性问题 (34) 表述为 LP 问题并写出 LP 问题的对偶问题。将 LP 对偶与 (1) 中所求得的对偶问题联系起来。

作业 III

3. 设有若干二分类问题的观测样本 $\{(x_i, y_i)\}_{i=1}^n \subseteq \mathbf{R}^d \times \{+1, -1\}$, 考虑线性支持向量机模型:

$$\min_{w \in \mathbf{R}^d, b \in \mathbf{R}} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n l(x_i, y_i; \mathbf{w}, b) \quad (39)$$

$c > 0$ 为参数, $l(x_i, y_i; \mathbf{w}, b) = \max(0, 1 - y_i(\mathbf{w}^\top x_i + b))$ 为样本点 (x_i, y_i) 的经验损失, 对应 Hinge 损失函数 $l(t) = \max(0, 1 - t)$, 函数 $y(x) = w^\top x + b$ 为判别函数。

- (1) 将线性支持向量机模型化为凸二次规划模型, 并写出该规划模型的对偶问题。
- (2) 结合凸二次规划模型的最优化条件, 说明哪些样本对模型起作用, 哪些不起作用。

作业 IV

4. 通过引入新变量 $y_i \in \mathbf{R}^{m_i}$ 以及等式约束 $y_i = A_i x + b_i$, 推导出下式的对偶问题

$$\text{minimize} \quad \sum_{i=1}^N \|A_i x + b_i\|_2 \quad (40)$$

其中 $A_i \in \mathbf{R}^{m_i \times n}, b_i \in \mathbf{R}^{m_i}$

5. 考虑 Lasso 模型

$$\text{minimize} \quad \|Ax + b\|^2 + \lambda \cdot |x|_1 \quad (41)$$

其中 $A \in \mathbf{R}^{m \times n}, b \in \mathbf{R}^m, \lambda > 0$, 假设模型有唯一解, 证明该模型的最优解关于 λ 是分段线性的。

作业 V

6. 考虑 QCQP 问题

$$\begin{aligned} & \text{minimize} && \frac{1}{2}(x_1^2 + x_2^2) - 4 \\ & \text{subject to} && (x_1 - 1)^2 + (x_2 - 1)^2 \leq 4 \end{aligned} \quad (42)$$

其中变量 $x \in \mathbb{R}^2$

- (1) 写出最优点 x^* 和最优值 p^* 。
- (2) 写出 KKT 条件。
- (3) 求解 Lagrange 对偶问题并说明强对偶性是否成立。

7. 推导出下面问题的 KKT 条件

$$\begin{aligned} & \text{minimize} && \text{tr } X - \log \det X \\ & \text{subject to} && Xs = y \end{aligned} \quad (43)$$

其中 $X \in \mathbf{S}^n$, 定义域 \mathbf{s}_{++}^n 。已知 $y \in \mathbf{R}^n, s \in \mathbf{R}^n$ 且 $s^\top y = 1$, 证明最优解为

$$X^* = I + yy^\top - \frac{1}{s^\top s} ss^\top \quad (44)$$