

## 5.7 最小二乘问题

SMaLL

<sup>1</sup> 中国石油大学（华东）

SMaLL 课题组

[small.sem.upc.edu.cn](http://small.sem.upc.edu.cn)

liangxijunsd@163.com

2023

# 最小二乘问题

1. 最小二乘法
2. 高斯-牛顿 (Gauss-Newton) 法
3. 增量梯度方法

# 最小二乘法

$$\begin{array}{ll}\text{minimize} & f(x) = \frac{1}{2} \|g(x)\|^2 = \frac{1}{2} \sum_{i=1}^m \|g_i(x)\|^2 \\ \text{subject to} & x \in \mathbb{R}^n\end{array}$$

其中  $g$  是一个连续可微函数，具有分量函数  $g_1, \dots, g_m$ ，其中  $g_i : \mathbb{R}^n \rightarrow \mathbb{R}^{r_i}$ .

# 示例

假设模型：

$$z = h(\theta, x).$$

目标. 估计  $n$  个参数  $\theta \in \mathbb{R}^n$ .

- $h$  是已知的能够刻画这个模型的函数
- $\theta \in \mathbb{R}^n$  是未知参数的向量
- $x \in \mathbb{R}^p$  是模型的输入
- $z \in \mathbb{R}^r$  是模型的输出

# 示例

- 数据.  $m$  个输入-输出对  $(x_1, z_1), \dots, (x_m, z_m)$
- 模型. 最小化误差平方和

$$\frac{1}{2} \sum_{i=1}^m \|z_i - h(\theta, x_i)\|^2$$

- E.g., 用三次多项式近似拟合数据:

$$h(\theta, x) = \theta_3 x^3 + \theta_2 x^2 + \theta_1 x + \theta_0$$

其中  $\theta = (\theta_0, \theta_1, \theta_2, \theta_3)$  是未知系数的向量.

# 最小二乘问题

1. 最小二乘法
2. 高斯-牛顿 (Gauss-Newton) 法
3. 增量梯度方法

## Sec. 2 高斯-牛顿法

注意下面的迭代格式中,  $x^k$  表示迭代点, 对应最小二乘拟合问题中的参数, 并不是样本点。

- 给定迭代点  $x^k$ , 高斯-牛顿迭代法的基本思想是用如下函数的线性化函数近似  $g$ :

$$\tilde{g}(x, x^k) = g(x^k) + \nabla g(x^k)^T (x - x^k)$$

- 最小化线性化函数  $\tilde{g}$  的范数:

$$\begin{aligned} x^{k+1} &= \arg \min_{x \in \mathbb{R}^n} \frac{1}{2} \|\tilde{g}(x, x^k)\|^2 \\ &= \arg \min_{x \in \mathbb{R}^n} \frac{1}{2} \left\{ \|g(x^k)\|^2 + 2(x - x^k)^T \nabla g(x^k) g(x^k) \right. \\ &\quad \left. + (x - x^k)^T \nabla g(x^k) \nabla g(x^k)^T (x - x^k) \right\}. \end{aligned}$$

# 高斯-牛顿法

假设  $\nabla g(x^k) \nabla g(x^k)^T \in \mathbb{R}^{n \times n}$  是可逆的:

$$x^{k+1} = x^k - (\nabla g(x^k) \nabla g(x^k)^T)^{-1} \nabla g(x^k) g(x^k) \quad (1)$$

- 如果  $g$  本身是线性函数  $\Rightarrow \|g(x)\|^2 = \|\tilde{g}(x, x^k)\|^2$ , 则该方法会在一次迭代后收敛。
- 方向

$$- (\nabla g(x^k) \nabla g(x^k)^T)^{-1} \nabla g(x^k) g(x^k)$$

是下降方向因为  $\nabla g(x^k) g(x^k) = \nabla (0.5 \|g(x)\|^2) |_{x=x^k}$  且  $(\nabla g(x^k) \nabla g(x^k)^T)^{-1}$  是正定矩阵.



# 高斯-牛顿法

为了确保矩阵  $\nabla g(x^k) \nabla g(x^k)^T$  是奇异矩阵（或接近奇异）时该方法也有效，迭代公式修正为：

$$x^{k+1} = x^k - \alpha^k (\nabla g(x^k) \nabla g(x^k)^T + \Delta^k)^{-1} \nabla g(x^k) g(x^k)$$

其中  $\Delta^k$  是一个对角矩阵，使得：

$$\nabla g(x^k) \nabla g(x^k)^T + \Delta^k \text{ 为正定矩阵.}$$

- 高斯-牛顿法所使用的方向与梯度相关并且符合梯度下降法的收敛结果。

# 与牛顿法的关系

- 假定每个  $g_i$  是一个标量函数,

$$\nabla^2 (0.5\|g(x)\|^2) = \nabla g(x^k) \nabla g(x^k)^T + \sum_{i=1}^m \nabla^2 g_i(x^k) g_i(x^k)$$

- 在高斯-牛顿法中 “近似的 Hessian 矩阵为”:

$$\nabla g(x^k) \nabla g(x^k)^T.$$

- 高斯-牛顿法的迭代公式:

$$x^{k+1} = x^k - \left( \nabla g(x^k) \nabla g(x^k)^T \right)^{-1} \nabla g(x^k) g(x^k) \quad (2)$$

- 优点: 它简化了计算.
- 缺点: 收敛速度较慢.

# 与牛顿法的关系

- 如果被忽略项  $\sum_{i=1}^m \nabla^2 g_i(x^k) g_i(x^k)$  在解附近很小  $\rightarrow$  良好的收敛速度
- E.g.1 当  $g$  接近线性时, 或者当分量  $g_i(x)$  在解附近很小时.
- E.g.2  $g(x) = 0, m = n$ .  
 $\rightarrow$  被忽略的项在解处接近零。
- 假定  $\nabla g(x^k)$  是可逆的,

$$(\nabla g(x^k) \nabla g(x^k)^T)^{-1} \nabla g(x^k) g(x^k) = (\nabla g(x^k)^T)^{-1} g(x^k)$$

- 高斯-牛顿法的迭代公式化简为:

$$x^{k+1} = x^k - (\nabla g(x^k)^T)^{-1} g(x^k) \quad (3)$$

# 最小二乘问题

1. 最小二乘法
2. 高斯-牛顿 (Gauss-Newton) 法
3. 增量梯度方法

## Sec. 3 增量梯度方法

- 每个分量  $g_i$ : 一个数据块.
- $x^k \rightarrow x^{k+1}$ : 数据块的循环
- 初始:  $\psi_0 = x^k$
- 进行  $m$  步循环:

$$\psi_i = \psi_{i-1} - \alpha^k \nabla g_i(\psi_{i-1}) g_i(\psi_{i-1}), \quad i = 1, \dots, m$$

其中  $\alpha^k > 0$  为步长, 方向为第  $i$  个数据块的梯度:

$$\nabla \left( \frac{1}{2} \|g_i(x)\|^2 \right) \Big|_{x=\psi_{i-1}} = \nabla g_i(\psi_{i-1}) g_i(\psi_{i-1})$$

# 增量梯度方法

该方法可以写作如下形式

$$x^{k+1} = x^k - \alpha^k \sum_{i=1}^m \nabla g_i(\psi_{i-1}) g_i(\psi_{i-1}) \quad (4)$$

## 不同点

- 增量梯度方法的方向:

$$-\sum_{i=1}^m \nabla g_i(\psi_{i-1}) g_i(\psi_{i-1})$$

- 梯度法的方向:

$$-\nabla f(x^k) = -\sum_{i=1}^m \nabla g_i(x^k) g_i(x^k)$$

# 增量梯度方法

## 优势:

- 适合数据流场景;
- 每一轮参数的更新速度都大大加快.

# 练习题

1. 编程. 生成  $m$  个输入-输出对  $(x_1, z_1), \dots, (x_m, z_m)$ , 其中  $x_i \in \mathbb{R}$ , 考虑三次多项式近似拟合数据的最小化误差平方和模型:

$$\min_{\theta} \frac{1}{2} \sum_{i=1}^m \|z_i - h(\theta, x_i)\|^2 \quad (5)$$

其中  $h$  为三次多项式  $h(\theta, x) = \theta_3 x^3 + \theta_2 x^2 + \theta_1 x + \theta_0$ , 编程实现高斯-牛顿法, 求解上述最小化误差平方和模型, 计算拟合误差。