

6.4 交替方向乘子法

SMaLL

¹ 中国石油大学（华东）

SMaLL 课题组

small.sem.upc.edu.cn

liangxijunsd@163.com

2023

交替方向乘子法 (ADMM)

1. 对偶上升法 Dual Ascent
2. 乘子法
3. 交替方向乘子法
4. 收敛性
5. 例子

对偶问题

考虑凸函数等式约束优化问题

$$\begin{array}{ll}\text{minimize} & f(x) \\ \text{subject to} & Ax = b\end{array}\quad (1)$$

- 拉格朗日函数: $L(x, y) = f(x) + y^T(Ax - b)$
- 对偶函数: $g(y) = \inf_x L(x, y)$
- 对偶问题: maximize $g(y)$
- 原始

$$x^* = \operatorname{argmin}_x L(x, y^*)$$

$$y^* = \operatorname{argmax}_y g(y)$$

对偶上升法

- 对于对偶问题: $y^{k+1} = y^k + \alpha^k \nabla g(y^k)$
- $\tilde{x} = \operatorname{argmin}_x L(x, y^k) \rightarrow \nabla g(y^k) = A\tilde{x} - b$
- 对偶上升

$$\begin{aligned} x^{k+1} &:= \operatorname{argmin}_x L(x, y^k) && // x\text{-minimization} \\ y^{k+1} &:= y^k + \alpha^k (Ax^{k+1} - b) && // \text{dual update} \end{aligned} \tag{2}$$

使用大量有力的假设

对偶分解

假设 f 是可分离的:

$$f(x) = f_1(x_1) + \cdots + f_N(x_N), x = (x_1, \dots, x_N) \quad (3)$$

→ L 在 x 中是可分离的:

$$\begin{aligned} L(x, y) &= L_1(x_1, y) + \cdots + L_N(x_N, y) - y^T b, \\ L_i(x_i, y) &= f_i(x_i) + y^T A_i x_i \end{aligned} \quad (4)$$

→ 在对偶上升法中, 最小化 x 分裂为 N 个最小化

$$x_i^{k+1} := \operatorname{argmin}_{x_i} L_i(x_i, y^k) \quad (5)$$

并且可以同时进行

对偶分解

对偶分解

$$\begin{aligned}x_i^{k+1} &:= \operatorname{argmin}_{x_i} L_i(x_i, y^k), \quad i = 1, \dots, N \\ y^{k+1} &:= y^k + \alpha^k \left(\sum_{i=1}^N A_i x_i^{k+1} - b \right)\end{aligned}\tag{6}$$

伴随许多假设 \rightarrow 乘子法

交替方向乘子法 (ADMM)

1. 对偶上升法 Dual Ascent
2. 乘子法
3. 交替方向乘子法
4. 收敛性
5. 例子

乘子法

一种具有良好鲁棒性的对偶上升方法

- 使用增广拉格朗日函数, $\rho > 0$

$$L_\rho(x, y) = f(x) + y^T(Ax - b) + (\rho/2)\|Ax - b\|_2^2 \quad (7)$$

- 乘子法

$$\begin{aligned} x^{k+1} &:= \operatorname{argmin}_x L_\rho(x, y^k) \\ y^{k+1} &:= y^k + \rho(Ax^{k+1} - b) \end{aligned} \quad (8)$$

二次惩罚破坏了更新后 x 的, 因此无法对其进行分解.

交替方向乘子法 (ADMM)

1. 对偶上升法 Dual Ascent
2. 乘子法
3. 交替方向乘子法
4. 收敛性
5. 例子

交替方向乘子法

- 对偶上升法: 支持对偶分解
- 乘子法: 良好的鲁棒性

→ 交替方向乘子法 (ADMM)

交替方向乘子法

ADMM 算法主要用于求解下列形式的优化问题 (其中 f, g 是凸函数)

$$\begin{array}{ll} \text{minimize} & f(x) + g(z) \\ \text{subject to} & Ax + Bz = c \end{array} \quad (9)$$

- 其中 $x \in \mathbf{R}^n$ 且 $z \in \mathbf{R}^m$
- $A \in \mathbf{R}^{p \times n}, B \in \mathbf{R}^{p \times m}$, 且 $c \in \mathbf{R}^p$

交替方向乘子法

考虑一般线性等式约束凸优化问题

$$\begin{array}{ll} \text{minimize} & f(x) \\ \text{subject to} & Ax = b, \end{array} \quad (10)$$

- $x \in \mathbf{R}^n$
- $A \in \mathbf{R}^{m \times n}$
- $f: \mathbf{R}^n \rightarrow \mathbf{R}$ 是凸的

交替方向乘子法

变量 $x \rightarrow$ 被分成了两个部分, x 和 z

$$\begin{array}{ll}\text{minimize} & f(x) + g(z) \\ \text{subject to} & Ax + Bz = c\end{array}\quad (11)$$

最优解可以由下式表示:

$$p^* = \inf\{f(x) + g(z) \mid Ax + Bz = c\}.\quad (12)$$

它的增广拉格朗日函数如下

$$L_\rho(x, z, y) = f(x) + g(z) + y^T(Ax + Bz - c) + (\rho/2)\|Ax + Bz - c\|_2^2 \quad (13)$$

交替方向乘子法

如果我们联合最小化两个变量 x, z , 归约为乘子法

$$\begin{aligned} (x^{k+1}, z^{k+1}) &:= \underset{x, z}{\operatorname{argmin}} L_{\rho}(x, z, y^k) \\ y^{k+1} &:= y^k + \rho (Ax^{k+1} + Bz^{k+1} - c). \end{aligned} \tag{14}$$

其中第一步关于两个原始变量联合最小化增广拉格朗日函数在 ADMM 中, x 的更新步骤与 z 的更新步骤次序将会**调换**.

交替方向乘子法

ADMM 由迭代组成

$$\begin{aligned}x^{k+1} &:= \underset{x}{\operatorname{argmin}} L_{\rho}(x, z^k, y^k), \quad // \text{ } x \text{-minimization step} \\z^{k+1} &:= \underset{z}{\operatorname{argmin}} L_{\rho}(x^{k+1}, z, y^k), \quad // \text{ } z \text{-minimization step} \\y^{k+1} &:= y^k + \rho(Ax^{k+1} + Bz^{k+1} - c), \quad // \text{ dual variable update}\end{aligned}\tag{15}$$

其中 $\rho > 0$. ADMM 类似于对偶上升法和乘子法.

标度变换形式

- 定义残差 $r = Ax + Bz - c$,

$$\begin{aligned} y^T r + (\rho/2) \|r\|_2^2 &= (\rho/2) \|r + (1/\rho)y\|_2^2 - (1/2\rho) \|y\|_2^2 \\ &= (\rho/2) \|r + u\|_2^2 - (\rho/2) \|u\|_2^2, \end{aligned} \quad (16)$$

其中 $u = (1/\rho)y$ 为标度变换.

- ADMM (标度对偶形式):

$$\begin{aligned} x^{k+1} &:= \operatorname{argmin}_x \left(f(x) + (\rho/2) \|Ax + Bz^k - c + u^k\|_2^2 \right) \\ z^{k+1} &:= \operatorname{argmin}_z \left(g(z) + (\rho/2) \|Ax^{k+1} + Bz - c + u^k\|_2^2 \right) \\ u^{k+1} &:= u^k + Ax^{k+1} + Bz^{k+1} - c \end{aligned} \quad (17)$$

交替方向乘子法 (ADMM)

1. 对偶上升法 Dual Ascent
2. 乘子法
3. 交替方向乘子法
4. 收敛性
5. 例子

收敛性

假设 1.. 扩展实值函数 $f: \mathbf{R}^n \rightarrow \mathbf{R} \cup \{+\infty\}$ 以及 $g: \mathbf{R}^m \rightarrow \mathbf{R} \cup \{+\infty\}$ 是闭的、正常的、凸的.

函数 f 满足假设 1 \leftrightarrow

$$\text{epi}f = \{(x, t) \in \mathbf{R}^n \times \mathbf{R} \mid f(x) \leq t\} \quad (18)$$

\Rightarrow

- 意味着 x 的更新和 z 的更新中产生的子问题是可解的.
- 允许 f 和 g 不可微, 并且函数值可取为 $+\infty$

收敛性

Assumption. [假设 2.] 拉格朗日函数 L_0 有一个鞍点.

具体地说, 存在 (可能不是唯一的) 点对 (x^*, z^*, y^*) , 对所有的 x, z, y 下式成立

$$L_0(x^*, z^*, y) \leq L_0(x^*, z^*, y^*) \leq L_0(x, z, y^*)$$

连续性

在假设 1 和假设 2 下, ADMM 算法具有以下性质:

- 残差收敛. $r^k \rightarrow 0, k \rightarrow \infty$,
即迭代点列逼近可行解.
- 目标函数收敛. $f(x^k) + g(z^k) \rightarrow p^*$ as $k \rightarrow \infty$,
即迭代的目标函数逼近最优值.
- 对偶变量收敛. $y^k \rightarrow y^*, k \rightarrow \infty$,
其中 y^* 是对偶最优解.

交替方向乘子法 (ADMM)

1. 对偶上升法 Dual Ascent
2. 乘子法
3. 交替方向乘子法
4. 收敛性
5. 例子

凸优化约束

考虑 ADMM 对于一般问题

$$\begin{array}{ll}\text{minimize} & f(x) \\ \text{subject to} & x \in \mathcal{C}\end{array}\quad (19)$$

ADMM 的迭代格式: 以 g 作为 \mathcal{C} 的指标

$$\begin{array}{ll}\text{minimize} & f(x) + g(z) \\ \text{subject to} & x - z = 0\end{array}\quad (20)$$

算法:

$$\begin{aligned}x^{k+1} &:= \operatorname{argmin}_x \left(f(x) + (\rho/2) \|x - z^k + u^k\|_2^2 \right) \\ z^{k+1} &:= \Pi_{\mathcal{C}} \left(x^{k+1} + u^k \right) \\ u^{k+1} &:= u^k + x^{k+1} - z^{k+1}\end{aligned}\quad (21)$$

Lasso

Lasso 问题

$$\text{minimize } (1/2)\|Ax - b\|_2^2 + \lambda\|x\|_1 \quad (22)$$

ADMM 的迭代格式:

$$\begin{aligned} &\text{minimize} && f(x) + g(z) \\ &\text{subject to} && x - z = 0 \end{aligned} \quad (23)$$

- $f(x) = (1/2)\|Ax - b\|_2^2$
- $g(z) = \lambda\|z\|_1$

ADMM:

$$\begin{aligned} x^{k+1} &:= (A^T A + \rho I)^{-1} (A^T b + \rho (z^k - u^k)) \\ z^{k+1} &:= S_{\lambda/\rho} (x^{k+1} + u^k) \\ u^{k+1} &:= u^k + x^{k+1} - z^{k+1}. \end{aligned} \quad (24)$$

Bi-convex 问题

另一个使用精确 ADMM 更新的重要问题是双凸规划 (bi-convex),

$$\begin{aligned} & \text{minimize} && F(x, z) \\ & \text{subject to} && G(x, z) = 0 \end{aligned} \tag{25}$$

- $F: \mathbf{R}^n \times \mathbf{R}^m \rightarrow \mathbf{R}$ 是 bi-convex 的

当 F 在 x 和 z 中是可分离的, G 关于 x 和 z 中是共同仿射时,
 \Rightarrow 模型就简化为标准的 ADMM 可求解的模型的形式.

Bi-convex 问题

ADMM 的迭代格式:

$$\begin{aligned}x^{k+1} &:= \operatorname{argmin}_x \left(F(x, z^k) + (\rho/2) \|G(x, z^k) + u^k\|_2^2 \right) \\z^{k+1} &:= \operatorname{argmin}_z \left(F(x^{k+1}, z) + (\rho/2) \|G(x^{k+1}, z) + u^k\|_2^2 \right) \\u^{k+1} &:= u^k + G(x^{k+1}, z^{k+1})\end{aligned}\tag{26}$$

由于 x 和 z 的更新仅涉及到凸优化问题, 因此易于处理.

当 $G = 0$ 时, \Rightarrow ADMM 退化为交替极小化算法, 这也是 Bi-convex 极小化的标准方法.

非负矩阵分解问题

考虑如下非负矩阵分解问题:

$$\begin{aligned} & \text{minimize} && (1/2) \| VW - C \|_F^2 \\ & \text{subject to} && V_{ij} \geq 0, \quad W_{ij} \geq 0, \end{aligned} \tag{27}$$

其中 $V \in \mathbf{R}^{p \times r}$, $W \in \mathbf{R}^{r \times q}$, 且数据 $C \in \mathbf{R}^{p \times q}$

- 目标函数是双仿射的
- 但没有等式约束

⇒ 因此 ADMM 成为非负矩阵分解的标准方法, 交替地在

- 最小化 V , 在 W 固定时
- 最小化 W , 在 V 固定时

非负矩阵分解问题

我们还可以引入一个新变量，将目标中的双线性项移到约束中：

$$\begin{array}{ll}\text{minimize} & (1/2)\|X - C\|_F^2 + I_+(V) + I_+(W) \\ \text{subject to} & X - VW = 0\end{array}\quad (28)$$

其中变量为 X, V, W ,

I_+ 是元素非负矩阵的指示函数.

非负矩阵分解问题

因为 (X, V) 代替的是 x , W 代替 z ,

$$\begin{aligned}(X^{k+1}, V^{k+1}) &:= \operatorname{argmin}_{X, V \geq 0} \left(\|X - C\|_F^2 + (\rho/2) \|X - VW^k + U^k\|_F^2 \right) \\ W^{k+1} &:= \operatorname{argmin}_{W \geq 0} \|X^{k+1} - V^{k+1}W + U^k\|_F^2 \\ U^{k+1} &:= U^k + X^{k+1} - V^{k+1}W^{k+1}\end{aligned}\tag{29}$$

Step 1 分离 X 和 V , 其中 X 和 V 可以通过求解二次规划得到,

Step 2 计算 W , 可以通过并行的求解二次规划来计算矩阵 W 的每一列.

习题:

运用 ADMM 求解 lasso 问题

参考文献和进一步阅读

Extensions and/or analyses:

- Stephen P. Boyd, Neal Parikh, Eric Chu, Borja Peleato, Jonathan Eckstein: Distributed Optimization and Statistical Learning via the Alternating Direction Method of Multipliers. Found. Trends Mach. Learn. 3(1): 1-122 (2011)

参考文献和进一步阅读

Helpful lecture notes/books:

- Ryan Tibshirani. Convex Optimization.
<http://www.stat.cmu.edu/~ryantibs/convexopt/>
- E. Candes, Lecture notes for Math 301, Stanford University,
Winter 2010 – 2011