

第 3 章 凸优化模型

SMaLL

¹ 中国石油大学（华东）

SMaLL 课题组

small.sem.upc.edu.cn

liangxijunsd@163.com

2023

1. 凸优化问题

1.1 标准形式的优化问题

1.2 凸优化问题

1.3 线性规划

1.4 二次规划

1.5 几何规划

1.6 广义不等式约束

1.7 半定规划 Semidefinite program

本章要点

- 掌握凸优化问题的形式，能够识别凸优化问题
- 了解拟凸优化的形式
- 掌握线性规划和二次规划的形式，能够识别这两类优化问题，并能够调用软件包解决问题
- 掌握二阶锥规划和半定规划 (semidefinite prog.) 的形式，能够识别这两类优化问题，并能够调用软件包解决问题

1. 凸优化问题

1.1 标准形式的优化问题

1.2 凸优化问题

1.3 线性规划

1.4 二次规划

1.5 几何规划

1.6 广义不等式约束

1.7 半定规划 Semidefinite program

标准形式的优化问题

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p\end{array} \quad (1)$$

- $x \in \mathbb{R}^n$ 是优化变量
- $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ 是目标函数或代价函数
- $f_i : \mathbb{R}^n \rightarrow \mathbb{R}, i = 1, \dots, m$, 是不等式约束函数
- $h_i : \mathbb{R}^n \rightarrow \mathbb{R}$ 是等式约束函数

隐式约束

$$x \in \mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i, \quad (2)$$

- 我们称 \mathcal{D} 为问题的**定义域**
- 约束 $f_i(x) \leq 0, h_i(x) = 0$ 是**显式约束**
- 如果一个问题没有明确的约束 ($m = p = 0$), 它就是**不受约束的**

例.

$$\text{minimize} \quad f_0(x) = - \sum_{i=1}^k \log(b_i - a_i^T x) \quad (3)$$

是一个具有隐式约束 $a_i^T x < b_i$ 的无约束问题

最优点和局部最优点

定义. 如果 $x \in \text{dom } f_0$ 并且满足约束条件, 则称 x 是 **可行的最优点** p^* :

$$p^* = \inf \{f_0(x) \mid f_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, p\} \quad (4)$$

如果 $f_0(x) = p^*$ 称这个可行的 x 为 **最优解**; X_{opt} 是所有最优解的集合

x 是 **局部最优**的如果存在 $R > 0$ 使得 x 是下面关于 z 优化问题的解

$$\begin{aligned} & \text{minimize (over } z) && f_0(z) \\ & \text{subject to} && f_i(z) \leq 0, \quad i = 1, \dots, m, \quad h_i(z) = 0, \quad i = 1, \dots, p \\ & && \|z - x\|_2 \leq R \end{aligned} \quad (5)$$

例. ($n = 1, m = p = 0$)

- $f_0(x) = 1/x$, $\text{dom } f_0 = \mathbb{R}_{++} : p^* = 0$, 无最优点
- $f_0(x) = -\log x$, $\text{dom } f_0 = \mathbb{R}_{++} : p^* = -\infty$
- $f_0(x) = x \log x$, $\text{dom } f_0 = \mathbb{R}_{++} : p^* = -1/e, x = 1/e$ 是最优点
- $f_0(x) = x^3 - 3x$, $p^* = -\infty$, 在 $x = 1$ 处局部最优

可行性问题

$$\begin{array}{ll}\text{find} & x \\ \text{subject to} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p\end{array} \quad (6)$$

当 $f_0(x) = 0$ 时，可以认为是一般问题的特例：

$$\begin{array}{ll}\text{minimize} & 0 \\ \text{subject to} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p\end{array} \quad (7)$$

- 如果约束条件可行，那么 $p^* = 0$ ；任何可行的 x 都是最佳的
- 如果约束不可行，那么 $p^* = \infty$

1. 凸优化问题

1.1 标准形式的优化问题

1.2 凸优化问题

1.3 线性规划

1.4 二次规划

1.5 几何规划

1.6 广义不等式约束

1.7 半定规划 Semidefinite program

凸优化问题

标准形式的凸优化问题

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && a_i^T x = b_i, \quad i = 1, \dots, p \end{aligned} \tag{8}$$

- f_0, f_1, \dots, f_m 均为凸函数; 等式约束是仿射函数

重要性质: 凸优化问题的可行集是凸的

示例

凸优化问题

$$\begin{array}{ll}\text{minimize} & f_0(x) = x_1^2 + x_2^2 \\ \text{subject to} & f_1(x) = x_1 / (1 + x_2^2) \leq 0 \\ & h_1(x) = (x_1 + x_2)^2 = 0\end{array}\quad (9)$$

- f_0 是凸函数; 可行集 $\{(x_1, x_2) \mid x_1 = -x_2 \leq 0\}$ 是凸集
- (根据我们的定义) 并非一个凸优化问题: f_1 不是凸函数, h_1 不是仿射函数
- 与凸问题等价 (但不相同)

$$\begin{array}{ll}\text{minimize} & x_1^2 + x_2^2 \\ \text{subject to} & x_1 \leq 0 \\ & x_1 + x_2 = 0\end{array}\quad (10)$$

局部和全局最优

定理 1

凸问题的任何局部最优点都是（全局）最优的

证明. 假设 x 是局部最优的，但存在一个可行的 y ， $f_0(y) < f_0(x)$
 x 局部最优意味着存在 $R > 0$ 使得

$$z \text{ 可行}, \quad \|z - x\|_2 \leq R \implies f_0(z) \geq f_0(x) \quad (11)$$

令 $z = \theta y + (1 - \theta)x$ ，其中 $\theta = R / (2\|y - x\|_2)$

- $\|y - x\|_2 > R$, 所以 $0 < \theta < 1/2$
- z 是两个可行点的凸组合，因此也是可行的
- $\|z - x\|_2 = R/2$ 且

$$f_0(z) \leq \theta f_0(y) + (1 - \theta)f_0(x) < f_0(x) \quad (12)$$


这与我们的假设相悖，即 x 是局部最优的

可微函数 f_0 的最优性准则

定理 2

对于任何凸优化问题, x 是最优的, 当且仅当其可行且

$$\nabla f_0(x)^T(y - x) \geq 0 \quad \text{对所有可行 } y \quad (13)$$



其中可行集 x 由阴影表示, 如果非零, $\nabla f_0(x)$ 在 x 处定义了可行集 X 的一个支撑超平面

证明.

证明. \Leftarrow : f_0 为凸函数: $f_0(y) \geq f_0(x) + \langle \nabla f_0(x), y - x \rangle$,
 $\forall x, y \in \text{dom } f_0$

\Rightarrow : 假设 x 是最优的, $\exists y \in X$, 满足 $\langle \nabla f_0(x), y - x \rangle < 0$.

考虑点 $z(t) = ty + (1 - t)x$, 其中 $t \in [0, 1]$. X 是凸集 $\Rightarrow z(t)$ 是可行的.

对于较小的正数 t : $f_0(z(t)) < f_0(x)$, $\Rightarrow x$ 不是最优的. 为了说明这点:

$$\left. \frac{d}{dt} f_0(z(t)) \right|_{t=0} = \nabla f_0(x)^T (y - x) < 0$$

对于较小的正数 t : $f_0(z(t)) < f_0(x)$.

可微函数 f_0 的最优性准则

- **无约束问题:** x 是最优解, 当且仅当

$$x \in \mathbf{dom} f_0, \quad \nabla f_0(x) = 0 \quad (14)$$

- **等式约束问题**

$$\text{minimize } f_0(x) \quad \text{subject to } Ax = b \quad (15)$$

x 是最优解, 当且仅当存在一个 ν 使得

$$x \in \mathbf{dom} f_0, \quad Ax = b, \quad \nabla f_0(x) + A^T \nu = 0 \quad (16)$$

- **非负整数的最小化**

$$\text{minimize } f_0(x) \quad \text{subject to } x \succeq 0 \quad (17)$$

x 是最优解, 当且仅当

$$x \in \mathbf{dom} f_0, \quad x \succeq 0, \quad \begin{cases} \nabla f_0(x)_i \geq 0 & x_i = 0 \\ \nabla f_0(x)_i = 0 & x_i > 0 \end{cases} \quad (18)$$

等价凸问题

如果一个问题的解很容易从另一个问题中得到，则两个问题（非正式地）是**等价的**，反之亦然

保持凸性的一些常见变换：

- 消除等式约束

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq 0, \quad i = 1, \dots, m \\ & Ax = b\end{array} \quad (19)$$

等价于

$$\begin{array}{ll}\text{minimize (over } z) & f_0(Fz + x_0) \\ \text{subject to} & f_i(Fz + x_0) \leq 0, \quad i = 1, \dots, m\end{array} \quad (20)$$

其中 F 和 x_0 满足

$$Ax = b \iff x = Fz + x_0 (\text{对一切 } z) \quad (21)$$

等价凸问题

- 引入等式约束

$$\begin{array}{ll}\text{minimize} & f_0(A_0x + b_0) \\ \text{subject to} & f_i(A_ix + b_i) \leq 0, \quad i = 1, \dots, m\end{array}\quad (22)$$

等价于

$$\begin{array}{ll}\text{minimize (over } x, y_i) & f_0(y_0) \\ \text{subject to} & f_i(y_i) \leq 0, \quad i = 1, \dots, m \\ & y_i = A_ix + b_i, \quad i = 0, 1, \dots, m\end{array}\quad (23)$$

- 引入线性不等式的松弛变量

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & a_i^T x \leq b_i, \quad i = 1, \dots, m\end{array}\quad (24)$$

等价于

$$\begin{array}{ll}\text{minimize (over } x, s) & f_0(x) \\ \text{subject to} & a_i^T x + s_i = b_i, \quad i = 1, \dots, m \\ & s_i \geq 0, \quad i = 1, \dots, m\end{array}\quad (25)$$

等价凸问题

- 上图 (epigraph) 形式: 标准形式凸问题等价于

$$\begin{aligned} & \text{minimize (over } x, t) && t \\ & \text{subject to} && f_0(x) - t \leq 0 \\ & && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && Ax = b \end{aligned} \tag{26}$$

- 最小化某些变量

$$\begin{aligned} & \text{minimize} && f_0(x_1, x_2) \\ & \text{subject to} && f_i(x_1) \leq 0, \quad i = 1, \dots, m \end{aligned} \tag{27}$$

等价于

$$\begin{aligned} & \text{minimize} && \tilde{f}_0(x_1) \\ & \text{subject to} && f_i(x_1) \leq 0, \quad i = 1, \dots, m \end{aligned} \tag{28}$$

其中 $\tilde{f}_0(x_1) = \inf_{x_2} f_0(x_1, x_2)$

1. 凸优化问题

1.1 标准形式的优化问题

1.2 凸优化问题

1.3 线性规划

1.4 二次规划

1.5 几何规划


1.6 广义不等式约束

1.7 半定规划 Semidefinite program

线性规划 (LP)

$$\begin{array}{ll}\text{minimize} & c^T x + d \\ \text{subject to} & Gx \preceq h \\ & Ax = b\end{array}\quad (29)$$

- 目标函数和约束条件都是仿射函数的凸问题
- 可行集是多面体



示例

1. 饮食问题: 选择 n 种食物的数量 x_1, \dots, x_n

- 一个单位的食物 j 花费 c_j , 包含的营养 i 的数量为 a_{ij}
- 健康饮食需要的营养 i 在数量上至少为 b_i

为了找到最便宜的健康饮食方案,

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && Ax \succeq b, \quad x \succeq 0 \end{aligned} \tag{30}$$

2. 分段线性最小化问题

$$\text{minimize} \quad \max_{i=1, \dots, m} (a_i^T x + b_i) \tag{31}$$

等价于一个 LP 问题

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && a_i^T x + b_i \leq t, \quad i = 1, \dots, m \end{aligned} \tag{32}$$


示例

3. 多面体的切比雪夫中心

$$\mathcal{P} = \{x \mid a_i^T x \leq b_i, i = 1, \dots, m\} \quad (33)$$

的切比雪夫中心是最大内切球的中心

$$\mathcal{B} = \{x_c + u \mid \|u\|_2 \leq r\} \quad (34)$$



- $a_i^T x \leq b_i \quad \forall x \in \mathcal{B}$ 当且仅当

$$\sup \{a_i^T (x_c + u) \mid \|u\|_2 \leq r\} = a_i^T x_c + r \|a_i\|_2 \leq b_i \quad (35)$$

- 因此, x_c, r 可以通过求解 LP 问题来确定

$$\begin{aligned} & \text{maximize} && r \\ & \text{subject to} && a_i^T x_c + r \|a_i\|_2 \leq b_i, \quad i = 1, \dots, m \end{aligned} \quad (36)$$

例. 基于线性规划求解该多面体的切比雪夫中心


考虑下面的线性不等式组定义的多面体 \mathcal{P} :

$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \\ -1 & 0 \end{bmatrix} \cdot \begin{bmatrix} y \\ x \end{bmatrix} \preceq \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

运行代码, 基于线性规划求解该多面体的切比雪夫中心

基于线性规划求解该多面体的切比雪夫中心 (运行代码)

```
1 from scipy import optimize
2 import numpy as np
3 from matplotlib import pyplot as plt
4 c = np.array([1,0,0])
5 A = np.array([[np.sqrt(2),1,1],[np.sqrt(2),1,1],[1,-1,0]])
6 b = np.array([1,1,0])
7 res = optimize.linprog(-c,A,b)
8 res.x
9 plt.plot([-1,0],[0,1], 'b')
10 plt.plot([0,1],[1,0], 'b')
11 plt.plot([-1,1],[0,0], 'b')
12 r,x,y = res.x[0],res.x[2],res.x[1]
13 theta = np.arange(0,2*np.pi,0.01)
14 plt.plot(x+r*np.cos(theta),y+r*np.sin(theta), 'r')
15 plt.plot(x,y, 'k.')
16 plt.axis('equal')
```



多面体 P 及求得的切比雪夫中心，如图所示。

1. 凸优化问题

1.1 标准形式的优化问题

1.2 凸优化问题

1.3 线性规划

1.4 二次规划

1.5 几何规划


1.6 广义不等式约束

1.7 半定规划 Semidefinite program

二次规划 (QP)

$$\begin{array}{ll}\text{minimize} & (1/2)x^T Px + q^T x + r \\ \text{subject to} & Gx \preceq h \\ & Ax = b\end{array}\quad (37)$$

- $P \in \mathbf{S}_+^n$, 所以目标是凸二次函数
- 最小化多面体上的凸二次函数



示例

1. 最小二乘回归

$$\text{minimize} \quad \frac{1}{2} \|Ax - b\|_2^2 \quad (38)$$

- 解析解 $x^* = A^\dagger b$ (A^\dagger 是 A 的伪逆)
- 可以添加线性约束, *e.g.*, $l \preceq x \preceq u$

2. 具有随机成本的线性规划

$$\begin{aligned} \text{minimize} \quad & \bar{c}^T x + \gamma x^T \Sigma x = \mathbf{E} c^T x + \gamma \mathbf{var}(c^T x) \\ \text{subject to} \quad & Gx \preceq h, \quad Ax = b \end{aligned} \quad (39)$$

- c 是具有均值 \bar{c} 和协方差 Σ 的随机向量
- 因此, $c^T x$ 是具有平均值 $\bar{c}^T x$ 和方差 $x^T \Sigma x$ 的随机变量
- $\gamma > 0$ 是风险规避参数; 控制预期成本和差异 (风险) 之间的权衡

3. 多面体之间的距离

- 多面体 $\mathcal{P}_1 = \{\mathbf{x} \mid \mathbf{A}_1 \mathbf{x} \preceq \mathbf{b}_1\}$ 和 $\mathcal{P}_2 = \{\mathbf{x} \mid \mathbf{A}_2 \mathbf{x} \preceq \mathbf{b}_2\}$ 在 \mathbf{R}^n 上的欧氏距离定义为

$$\text{dist}(\mathcal{P}_1, \mathcal{P}_2) = \inf \{\|\mathbf{x}_1 - \mathbf{x}_2\|_2 \mid \mathbf{x}_1 \in \mathcal{P}_1, \mathbf{x}_2 \in \mathcal{P}_2\}$$

- 如果多面体相交，则距离为零。
- 求解下面的二次规划 $\rightarrow \mathcal{P}_1$ 和 \mathcal{P}_2 之间的距离

$$\begin{aligned} & \underset{\mathbf{x}_1, \mathbf{x}_2 \in \mathbf{R}^n}{\text{minimize}} && \|\mathbf{x}_1 - \mathbf{x}_2\|_2^2 \\ & \text{subject to} && \mathbf{A}_1 \mathbf{x}_1 \preceq \mathbf{b}_1, \mathbf{A}_2 \mathbf{x}_2 \preceq \mathbf{b}_2 \end{aligned}$$

- 当且仅当多面体相交时，最优值为零，否则最优解 \mathbf{x}_1 和 \mathbf{x}_2 分别是 \mathcal{P}_1 和 \mathcal{P}_2 中最接近的点

例. 二次规划求多面体间的距离

考虑多面体 \mathcal{P}_1

$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \\ -1 & 0 \end{bmatrix} \cdot \begin{bmatrix} y \\ x \end{bmatrix} \preceq \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$


和多面体 \mathcal{P}_2

$$\begin{bmatrix} 0 & -1 \\ -1 & 1 \\ 1 & 1 \end{bmatrix} \cdot \begin{bmatrix} y \\ x \end{bmatrix} \preceq \begin{bmatrix} -2 \\ 2 \\ 4 \end{bmatrix}$$

之间的距离。

学习实例代码 3.4.1, 基于二次规划求解上述两个多面体之间距离。

代码输出求得的最优解为: $[5.30\text{e}-04, 1.00\text{e}+00, 5.78\text{e}-04, 2.00\text{e}+00]$, 表示两个多面体相距最近的两个点近似为 $(1,0)$ 和 $(2,0)$ 。



如图展示了这两个多面体及其最相距最近的两个点。

二次约束二次规划 (QCQP)

$$\begin{aligned} & \text{minimize} && (1/2)x^T P_0 x + q_0^T x + r_0 \\ & \text{subject to} && (1/2)x^T P_i x + q_i^T x + r_i \leq 0, \quad i = 1, \dots, m \\ & && Ax = b \end{aligned} \quad (40)$$

- $P_i \in \mathbf{S}_+^n$; 目标函数和约束函数是凸二次函数
- 如果 $P_1, \dots, P_m \in \mathbf{S}_{++}^n$, 可行域是 m 个椭球和仿射集 $Ax = b$ 的交集

例. QCQP

$$\max \quad \theta$$

$$\text{s. t.} \quad \|\mu\|_2 \leq 1,$$

$$\mu_i \geq 0, i = 1, \dots, p,$$

$$\frac{1}{2} \sum_{i=1}^p \mu_i f_i(\alpha) - \sum_{i=1}^l \alpha_i \geq \theta,$$

$$0 \leq \alpha_i \leq s_i C, \quad i = 1, \dots, l,$$

$$\sum_{i=1}^l y_i \alpha_i = 0,$$

$$\text{where } f_i(\alpha) = \sum_{j,k=1}^l \alpha_j \alpha_k y_j y_k k^i(\mathbf{x}_j, \mathbf{x}_k), \quad i = 1, \dots, p.$$

Ling Jian, Zhonghang Xia, Xinnan Niu, Xijun Liang, Parimal Samir, Andrew J. Link: L2 基于多

核模糊支持向量机的多肽识别数据融合. IEEE ACM Trans. Comput. Biol. Bioinform. 13(4): 804-809

二阶锥规划

$$\begin{aligned} & \text{minimize} && f^T x \\ & \text{subject to} && \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m \\ & && Fx = g \end{aligned} \quad (41)$$

$$(A_i \in \mathbb{R}^{n_i \times n}, F \in \mathbb{R}^{p \times n})$$

- 不等式称为二阶锥 (SOC) 约束:

$$(A_i x + b_i, c_i^T x + d_i) \in \mathbb{R}^{n_i+1} \text{ 上的二阶锥} \quad (42)$$

\mathbb{R}^{n+1} 上的二阶锥: $\{(x, t) \in \mathbb{R}^{n+1} \mid \|x\|_2 \leq t\}$

- 当 $n_i = 0$, 简化成 LP 问题; 如果 $c_i = 0$, 变为一个 QCQP 问题
- 比 QCQP 和 LP 更普遍

例. 鲁棒线性规划

优化问题中的参数通常是不确定的, *e.g.*, 在 LP 问题中

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && a_i^T x \leq b_i, \quad i = 1, \dots, m \end{aligned} \tag{43}$$

在 c , a_i , b_i 中可能存在不确定性

处理不确定性的两种常见方法 (为了简单起见, 以 a_i 为例)

- 确定性模型: 约束必须适用于所有 $a_i \in \mathcal{E}_i$

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && a_i^T x \leq b_i \quad \forall a_i \in \mathcal{E}_i, \quad i = 1, \dots, m \end{aligned} \tag{44}$$

- 随机模型: a_i 为随机变量; 约束为概率约束

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && \mathbf{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m \end{aligned} \tag{45}$$

例. 鲁棒线性规划

确定性方法 \leftarrow SOCP (二阶锥规划) (自学)

- 选择椭球 \mathcal{E}_i :

$$\mathcal{E}_i = \{\bar{a}_i + P_i u \mid \|u\|_2 \leq 1\} \quad (\bar{a}_i \in \mathbb{R}^n, \quad P_i \in \mathbb{R}^{n \times n}) \quad (46)$$

球心是 \bar{a}_i , 由奇异值/向量 P_i 确定半轴

- 鲁棒线性规划问题

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && a_i^T x \leq b_i \quad \forall a_i \in \mathcal{E}_i, \quad i = 1, \dots, m \end{aligned} \quad (47)$$

等价于 SOCP (二阶锥规划)

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && \bar{a}_i^T x + \|P_i^T x\|_2 \leq b_i, \quad i = 1, \dots, m \end{aligned} \quad (48)$$

由于 $\sup_{\|u\|_2 \leq 1} (\bar{a}_i + P_i u)^T x = \bar{a}_i^T x + \|P_i^T x\|_2$

基于 SOCP (二阶锥规划) 的随机方法

- 假定 a_i 为高斯分布, 均值为 \bar{a}_i , 方差为 Σ_i ($a_i \sim \mathcal{N}(\bar{a}_i, \Sigma_i)$)
- $a_i^T x$ 是一个高斯 *r.v.*, 均值为 $\bar{a}_i^T x$, 方差为 $x^T \Sigma_i x$;

$$\mathbf{prob}(a_i^T x \leq b_i) = \Phi\left(\frac{b_i - \bar{a}_i^T x}{\left\|\Sigma_i^{1/2} x\right\|_2}\right) \quad (49)$$

其中 $\Phi(x) = (1/\sqrt{2\pi}) \int_{-\infty}^x e^{-t^2/2} dt$ 是 $\mathcal{N}(0, 1)$ 的分布函数

- 鲁棒线性规划

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && \mathbf{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m \end{aligned} \quad (50)$$

$\eta \geq 1/2$, 等价于 SOCP 问题

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && \bar{a}_i^T x + \Phi^{-1}(\eta) \left\|\Sigma_i^{1/2} x\right\|_2 \leq b_i, \quad i = 1, \dots, m \end{aligned} \quad (51)$$

例. 二阶锥规划问题

$$\begin{aligned} & \text{minimize} \quad -2x_1 + x_2 + 5x_3 \\ & \text{subject to} \quad \left\| \begin{bmatrix} -13x_1 + 3x_2 + 5x_3 - 3 \\ -12x_1 + 12x_2 - 6x_3 - 2 \end{bmatrix} \right\|_2 \leq -12x_1 - 6x_2 + 5x_3 - 12 \\ & \quad \left\| \begin{bmatrix} -3x_1 + 6x_2 + 2x_3 \\ x_1 + 9x_2 + 2x_3 + 3 \\ -x_1 - 19x_2 + 3x_3 - 42 \end{bmatrix} \right\|_2 \leq -3x_1 + 6x_2 - 10x_3 + 27 \end{aligned}$$

学习实例代码 3.4.2, 调用 Cvxopt 包求解上述问题, 所求得的最优解为 $[-5.01e + 00, -5.77e + 00, -8.52e + 00]$

1. 凸优化问题

1.1 标准形式的优化问题

1.2 凸优化问题

1.3 线性规划

1.4 二次规划

1.5 几何规划

1.6 广义不等式约束

1.7 半定规划 Semidefinite program

几何规划

单项式函数

$$f(x) = cx_1^{a_1} x_2^{a_2} \cdots x_n^{a_n}, \quad \text{dom } f = \mathbb{R}_{++}^n \quad (52)$$

$c > 0$; a_i 可以为任意实数

多项式函数: 单项式求和

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} x_2^{a_{2k}} \cdots x_n^{a_{nk}}, \quad \text{dom } f = \mathbb{R}_{++}^n \quad (53)$$

几何规划 (GP)

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 1, \quad i = 1, \dots, m \\ & && h_i(x) = 1, \quad i = 1, \dots, p \end{aligned} \quad (54)$$

f_i 为多项式, h_i 为单项式

凸形几何规划

将变量更改为 $y_i = \log x_i$, 并取目标和约束条件的对数

- 单项式 $f(x) = cx_1^{a_1} \cdots x_n^{a_n}$ 变为

$$\log f(e^{y_1}, \dots, e^{y_n}) = a^T y + b \quad (b = \log c) \quad (55)$$


- 多项式 $f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} x_2^{a_{2k}} \cdots x_n^{a_{nk}}$ 变为

$$\log f(e^{y_1}, \dots, e^{y_n}) = \log \left(\sum_{k=1}^K e^{a_k^T y + b_k} \right) \quad (b_k = \log c_k) \quad (56)$$

- 几何规划转变为凸问题

$$\begin{aligned} \text{minimize} \quad & \log \left(\sum_{k=1}^K \exp(a_{0k}^T y + b_{0k}) \right) \\ \text{subject to} \quad & \log \left(\sum_{k=1}^K \exp(a_{ik}^T y + b_{ik}) \right) \leq 0, \quad i = 1, \dots, m \\ & Gy + d = 0 \end{aligned} \quad (57)$$

悬臂梁设计



- 具有单位长度的线段 N ，大小 $w_i \times h_i$ 为矩形截面
- 给定右端施加的垂直力 F

设计问题

minimize 总重量

subject to w_i, h_i 上下界

纵横比 (aspect ratio) h_i/w_i 的上下界

每段应力的上下界

每段末尾的垂直偏转 (vertical deflection) 力的上界

悬臂梁设计

目标函数和约束条件

- 总重量 $w_1 h_1 + \cdots + w_N h_N$ 是多项式
- 纵横比 h_i/w_i 和反纵横比 w_i/h_i 是单项式
- 线段 i 中的最大应力由一个单项式给出 $6iF/(w_i h_i^2)$
- 线段 i 右端中心轴的垂直偏转 y_i 和斜率 v_i 递归定义为

$$\begin{aligned}v_i &= 12(i-1/2) \frac{F}{E w_i h_i^3} + v_{i+1} \\y_i &= 6(i-1/3) \frac{F}{E w_i h_i^3} + v_{i+1} + y_{i+1}\end{aligned}\tag{59}$$

$i = N, N-1, \dots, 1, v_{N+1} = y_{N+1} = 0$ (E 是杨氏模量)

v_i 和 y_i 是 w, h 的多项式函数

悬臂梁设计

构造一个 GP 问题

$$\begin{aligned} \text{minimize} \quad & w_1 h_1 + \cdots + w_N h_N \\ \text{subject to} \quad & w_{\max}^{-1} w_i \leq 1, \quad w_{\min} w_i^{-1} \leq 1, \quad i = 1, \dots, N \\ & h_{\max}^{-1} h_i \leq 1, \quad h_{\min} h_i^{-1} \leq 1, \quad i = 1, \dots, N \\ & S_{\max}^{-1} w_i^{-1} h_i \leq 1, \quad S_{\min} w_i h_i^{-1} \leq 1, \quad i = 1, \dots, N \\ & 6iF\sigma_{\max}^{-1} w_i^{-1} h_i^{-2} \leq 1, \quad i = 1, \dots, N \\ & y_{\max}^{-1} y_1 \leq 1 \end{aligned} \tag{60}$$

注意

- $w_{\min} \leq w_i \leq w_{\max}, h_{\min} \leq h_i \leq h_{\max} \rightarrow$
 $w_{\min}/w_i \leq 1, \quad w_i/w_{\max} \leq 1, \quad h_{\min}/h_i \leq 1, \quad h_i/h_{\max} \leq 1 \tag{61}$

- $S_{\min} \leq h_i/w_i \leq S_{\max} \leftarrow$
 $S_{\min} w_i/h_i \leq 1, \quad h_i/(w_i S_{\max}) \leq 1 \tag{62}$

最小化非负矩阵的谱半径

erron-Frobenius 特征值 $\lambda_{\text{pf}}(A)$

- 存在对每个元素都为正的矩阵 $A \in \mathbb{R}^{n \times n}$
- 实际的正特征值 A , 等于光谱半径 $\max_i |\lambda_i(A)|$
- 确定 A^k 的渐近增长 (衰减) 率: $A^k \sim \lambda_{\text{pf}}^k$ as $k \rightarrow \infty$
- 替代性特征: $\lambda_{\text{pf}}(A) = \inf\{\lambda \mid Av \preceq \lambda v \text{ for some } v \succ 0\}$

最小化多项式矩阵的谱半径

- 最小化 $\lambda_{\text{pf}}(A(x))$, 其中 $A(x)_{ij}$ 中元素是 x 的多项式
- 等效几何规划:

$$\begin{aligned} & \text{minimize} && \lambda \\ & \text{subject to} && \sum_{j=1}^n A(x)_{ij} v_j / (\lambda v_i) \leq 1, \quad i = 1, \dots, n \end{aligned} \tag{63}$$

变量为 λ, v, x

1. 凸优化问题

1.1 标准形式的优化问题

1.2 凸优化问题

1.3 线性规划

1.4 二次规划

1.5 几何规划

1.6 广义不等式约束

1.7 半定规划 Semidefinite program

广义不等式约束

具有广义不等式约束的凸问题

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \preceq_{K_i} 0, \quad i = 1, \dots, m \\ & && Ax = b \end{aligned} \tag{64}$$

- $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ 为凸函数; $f_i : \mathbb{R}^n \rightarrow \mathbb{R}^{k_i}$ K_i -凸, K_i : proper cone (正常锥)
- 与标准凸问题相同的性质 (凸可行集, 局部最优解是全局最优的, etc.)

锥形问题: 具有仿射目标函数和约束条件的特例

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && Fx + g \preceq_K 0 \\ & && Ax = b \end{aligned} \tag{65}$$

将线性规划 ($K = \mathbb{R}_+^m$) 推广到非多面体锥

1. 凸优化问题

1.1 标准形式的优化问题

1.2 凸优化问题

1.3 线性规划

1.4 二次规划

1.5 几何规划

1.6 广义不等式约束

1.7 半定规划 Semidefinite program

半定规划 (SDP)

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && x_1 F_1 + x_2 F_2 + \cdots + x_n F_n + G \preceq 0 \\ & && Ax = b \end{aligned} \quad (66)$$

其中 $F_i, G \in \mathbf{S}^k$

- 不等式约束称为线性矩阵不等式 (LMI)
- 包括具有多个 LMI 约束的问题: 例如,

$$x_1 \hat{F}_1 + \cdots + x_n \hat{F}_n + \hat{G} \preceq 0, \quad x_1 \tilde{F}_1 + \cdots + x_n \tilde{F}_n + \tilde{G} \preceq 0 \quad (67)$$

等价于单线矩阵不等式 SLM

$$x_1 \begin{bmatrix} \hat{F}_1 & 0 \\ 0 & \tilde{F}_1 \end{bmatrix} + x_2 \begin{bmatrix} \hat{F}_2 & 0 \\ 0 & \tilde{F}_2 \end{bmatrix} + \cdots + x_n \begin{bmatrix} \hat{F}_n & 0 \\ 0 & \tilde{F}_n \end{bmatrix} + \begin{bmatrix} \hat{G} & 0 \\ 0 & \tilde{G} \end{bmatrix} \preceq 0 \quad (68)$$

特征值最小化

$$\text{minimize} \quad \lambda_{\max}(A(x)) \quad (69)$$

其中 $A(x) = A_0 + x_1 A_1 + \cdots + x_n A_n$ (给定 $A_i \in \mathbf{S}^k$)
等价于 SDP 问题

$$\begin{aligned} &\text{minimize} && t \\ &\text{subject to} && A(x) \preceq tI \end{aligned} \quad (70)$$

- 变量 $x \in \mathbb{R}^n, t \in \mathbb{R}$
- 来自于

$$\lambda_{\max}(A) \leq t \iff A \preceq tI \quad (71)$$

矩阵范数最小化

$$\text{minimize} \quad \|A(x)\|_2 = (\lambda_{\max}(A(x)^T A(x)))^{1/2} \quad (72)$$

其中 $A(x) = A_0 + x_1 A_1 + \cdots + x_n A_n$ ($A_i \in \mathbb{R}^{p \times q}$ 给定) $\|A\|_2 = A$ 的最大奇异值 \leftrightarrow SDP

$$\begin{array}{ll} \text{minimize} & t \\ \text{subject to} & \begin{bmatrix} tI & A(x) \\ A(x)^T & tI \end{bmatrix} \succeq 0 \end{array} \quad (73)$$

- 变量 $x \in \mathbb{R}^n, t \in \mathbb{R}$
- 约束:

$$\begin{aligned} \|A\|_2 \leq t &\iff A^T A \preceq t^2 I, \quad t \geq 0 \\ &\iff \begin{bmatrix} tI & A \\ A^T & tI \end{bmatrix} \succeq 0 \end{aligned} \quad (74)$$

例. 最大割问题的半定规划松弛

- 设 G 是一个无向图, 顶点集合为 $\mathbf{N} = 1, 2, \dots, n$, 边的集合为 \mathbf{E}
- 设 $w_{ij} = w_{ji}$ 为边 (i, j) 上的权值, 其中 $(i, j) \in \mathbf{E}$ 。假设对于所有的 $(i, j) \in \mathbf{E}$, 都有 $w_{ij} > 0$
- 最大割问题是指确定顶点集合 \mathbf{N} 的一个子集 \mathbf{S} , 使连接顶点子集 \mathbf{S} 到它的余集 $\bar{\mathbf{S}}$ (其中 $\bar{\mathbf{S}} := \mathbf{N} \setminus \mathbf{S}$) 的所有的边权值之和最大
- 若 $j \in \mathbf{S}$, 则令 $x_j = -1$, 否则, 令 $x_j = 1$, 可以将最大割问题描述为如下的整数规划问题:

$$\begin{aligned} & \text{maximize} && \frac{1}{4} \sum_{i=1}^n \sum_{j=1}^n w_{ij} (1 - x_i x_j) \\ & \text{subject to} && x_j \in \{-1, 1\}, j = 1, 2, \dots, n \end{aligned}$$

例. 最大割问题的半定规划松弛

•

$$\begin{aligned} & \text{maximize} && \frac{1}{4} \sum_{i=1}^n \sum_{j=1}^n w_{ij} (1 - x_i x_j) \\ & \text{subject to} && x_j \in \{-1, 1\}, j = 1, 2, \dots, n \end{aligned}$$

• 令 $\mathbf{Y} = \mathbf{x}\mathbf{x}^T$, 其中 $Y_{ij} = x_i x_j, i = 1, 2, \dots, n, j = 1, 2, \dots, n$ 。

• 令 \mathbf{W} 为权矩阵, 即其第 i 行, 第 j 列的元素为

$w_{ij}, i = 1, 2, \dots, n, j = 1, 2, \dots, n$, 则最大割问题 \Leftrightarrow

$$\begin{aligned} & \text{maximize} && \frac{1}{4} \sum_{i=1}^n \sum_{j=1}^n w_{ij} - \mathbf{W} \cdot \mathbf{Y} \\ & \text{subject to} && x_j \in \{-1, 1\}, j = 1, 2, \dots, n \\ & && \mathbf{Y} = \mathbf{x}\mathbf{x}^T \end{aligned}$$

• 上述问题中第一部分约束等价于 $Y_{jj} = 1, j = 1, \dots, n \rightarrow$

$$\begin{aligned} & \text{maximize} && \frac{1}{4} \sum_{i=1}^n \sum_{j=1}^n w_{ij} - \mathbf{W} \cdot \mathbf{Y} \\ & \text{subject to} && Y_{jj} = 1, j = 1, 2, \dots, n \\ & && \mathbf{Y} = \mathbf{x}\mathbf{x}^T \end{aligned}$$

例. 最大割问题的半定规划松弛

- 矩阵 $\mathbf{Y} = \mathbf{x}\mathbf{x}^T$ 是一个秩为 1 的半正定矩阵 \rightarrow 松弛, 去掉秩为 1 这一限制 \rightarrow 半定规划松弛问题:

$$\begin{aligned} \text{maximize} \quad & \frac{1}{4} \sum_{i=1}^n \sum_{j=1}^n w_{ij} - \mathbf{W} \cdot \mathbf{Y} \\ \text{subject to} \quad & Y_{jj} = 1, j = 1, 2, \dots, n \\ & \mathbf{Y} \succeq 0 \end{aligned}$$

- 已知松弛问题 (RELAX) 为最大割问题 (MAXCUT) 提供了一个上界, 即:

$$MAXCUT \leq RELAX .$$

- 可以证明下面的不等式成立

$$0.8786 RELAX \leq MAXCUT \leq RELAX .$$

- \rightarrow 半定规划松弛问题的最优值与最大割这一 NP 难问题的最优值相差不超过 13%

例. 最大割问题的半定规划松弛

- 实例代码 3.6.1 给出了半定规划求解最大割问题的示例，其中有 5 个结点
- 学习代码，调用 `cvxpy` 包求解最大割问题的半定规划松弛问题

作业题

1. 设 $A \in \mathbb{R}^{n \times n}$, $c, d \in \mathbb{R}^n$, $d \in \mathbb{R}$, 证明: 映射 $\mathcal{A}: x \mapsto (Ax + b, c^T x + d)$, $\mathbb{R}^n \rightarrow \mathbb{R}^{n+1}$ 为仿射变换.
2. 编程题 (使用 Python): 求解鲁棒线性规划的二次规划问题

$$\begin{aligned} & \text{minimize} && \bar{c}^T x + \gamma x^T \Sigma x = \mathbf{E} c^T x + \gamma \mathbf{var}(c^T x) \\ & \text{subject to} && Gx \preceq h, \quad Ax = b \end{aligned} \tag{75}$$

c 是均值为 \bar{c} 方差为 Σ 的随机向量, 自行设置 \bar{c}, Σ 的值.

作业题

(选作) 3. 编程题 (使用 Python): 求解鲁棒 LP 的 SOCP 问题

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && \mathbf{prob}(a_i^T x \leq b_i) \geq \eta, \quad i = 1, \dots, m \end{aligned} \quad (76)$$

其中 $\eta \geq 1/2$, 等价于 SOCP 问题

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && \bar{a}_i^T x + \Phi^{-1}(\eta) \left\| \Sigma_i^{1/2} x \right\|_2 \leq b_i, \quad i = 1, \dots, m \end{aligned} \quad (77)$$

4. 利用 Python 绘制以下函数的图形

$$\log f(e^{y_1}, \dots, e^{y_n}) = \log \left(\sum_{k=1}^K e^{a_k^T y + b_k} \right) \quad (b_k = \log c_k) \quad (78)$$

with $y \in \mathbb{R}^2$.